

TEMA PARA PRÉ-PROJETO DE MESTRADO E DOUTORADO

1 - Identificação

Título do Projeto:	Data Stream Learning para TinyML
Orientador:	Rodrigo Gabriel Ferreira Soares
Grande Área:	Ciência da Computação
Área do Conhecimento:	Aprendizagem de Máquina e Mineração
Instituição de Execução:	Universidade Federal de Pernambuco - Centro de Informática (CIn-UFPE)

2 - Descrição

Técnicas de Tiny Machine Learning (TinyML) permitem que modelos de Machine Learning sejam embarcados em dispositivos com memória e capacidades computacionais extremamente limitadas, como unidades de microcontroladores, tecnologias de wearables, dispositivos de Internet of Things (IoT). Recentemente, TinyML migrou da simples execução de inferência de modelos de ML para toda a execução do aprendizado dos modelos de ML no próprio dispositivo (On-Device Learning - ODL), permitindo a adaptação dos algoritmos a dados pessoais e a ambientes específicos diretamente no dispositivo. No entanto, os trabalhos existentes sobre ODL pressupõem que todos os dados estejam disponíveis no dispositivo com rótulos, o que raramente ocorre na prática, uma vez que os dados são coletados ao longo do tempo e o processo de rotulagem exigiria intervenção humana constante. Embora algumas abordagens de Aprendizado Semissupervisionado tenham sido propostas no campo de Data Stream Learning, elas não são apropriadas para operar sob as restrições extremas do TinyML.

Este projeto propõe contribuições relevantes para Data Stream Learning no contexto de TinyML. As soluções geradas por este projeto permitirão que dispositivos com capacidade computacional severamente limitada executem inferência e treinamento de modelos de Machine Learning que aprendem tanto a partir de dados rotulados como dados não rotulados prontamente gerados nos próprios dispositivos em fluxos de dados potencialmente infinitos.

3 - Referências

R G F Soares, L L Minku, "Online ensemble model compression for nonstationary data stream learning" Neural Networks, vol. 185, 2025.

R G F Soares, L L Minku, "OSNN: An online semisupervised neural network for nonstationary data streams" IEEE Trans. Neu. Net. Learn. Sys., vol. 34, no. 9, 2023

SOARES, R. G. F.; FEITOSA, A. P. S. C.; GONCALVES, G.; VIDAL, D. A.. Self-evolving optimization for data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2024, Auckland. Neural Information Processing - Communications in Computer and Information Science. Springer Nature, 2025, v.2283.

VIDAL, D. A.; SOARES, R. G. F.; GONCALVES, G.; FEITOSA, A. P. S. C.; TAVARES, K. M.; SERUFFO, M. C. R.. A weight averaging neural network for semi-supervised data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2025, Auckland. Neural Information Processing - LNCS. Springer Nature, 2025, v.15287.

ELHANASHI, A. et al. Advancements in TinyML: Applications, Limitations, and Impact on IoT Devices. Electronics, v. 13, n. 17, p. 3562, 8 set. 2024.

SCHIZAS, N. et al. TinyML for Ultra-Low Power AI and Large Scale IoT Deployments: A Systematic Review. Future Internet, v. 14, n. 12, p. 363, 6 dez. 2022.

C. M. Bishop. Pattern Recognition and Machine Learning. Springer, 2006.

K. P. Murphy. The Machine Learning: A Probabilistic Perspective. Mit Press, 2012. ISBN 978-0262018029.
