

TEMA PARA PRÉ-PROJETO DE MESTRADO E DOUTORADO

1 - Identificação

Título do Projeto:	Algoritmos inteligentes de data stream learning para problemas com rótulos com atrasos
Orientador:	Rodrigo Gabriel Ferreira Soares
Grande Área:	Ciência da Computação
Área do Conhecimento:	Aprendizagem de Máquina e Mineração
Instituição de Execução:	Universidade Federal de Pernambuco - Centro de Informática (CIn-UFPE)

2 - Descrição

Fluxos de dados (data streams) consistem em sequências de instâncias de dados potencialmente infinitas geradas continuamente, frequentemente produzidas em altas velocidades. Essas instâncias são tipicamente independentes e podem se tornar disponíveis em diferentes quantidades a cada passo de tempo. Muitas aplicações do mundo real envolvem data streams, incluindo transações com cartão de crédito, processamento de dados da Internet das Coisas (IoT), transações de segurança cibernética, análise do comportamento do cliente, análise do mercado financeiro e assistência médica, entre outras. A classificação desses dados requer a manutenção de um modelo inteligente de decisão eficiente, especialmente em ambientes não estacionários.

Com o objetivo de atualizar modelos de decisão, a maioria dos algoritmos de classificação de fluxo de dados tradicionalmente se baseia em estratégias de aprendizado supervisionado. Essas abordagens dependem de dados rotulados para atualizações do modelo, tornando-as dependentes da disponibilidade desses dados. Em certas situações, especialistas do domínio podem ser solicitados a rotular um subconjunto dos dados, que pode ser selecionado de forma eficiente usando técnicas de Aprendizado Ativo (Active Learning). Por outro lado, alguns autores argumentam que muitos problemas do mundo real geralmente fornecem apenas exemplos não rotulados para atualizações do modelo. Esses cenários são abordados usando abordagens de aprendizado não supervisionado. Recentemente, tem havido um foco crescente no aprendizado semissupervisionado, que combina dados rotulados e não rotulados para atualizar modelos. Essa abordagem oferece uma representação mais precisa de muitas aplicações práticas.

Muitos algoritmos de classificação se baseiam em estratégias de aprendizado supervisionado, partindo do pressuposto de que o rótulo de cada instância se torna imediatamente disponível após sua chegada. No entanto, em ambientes de data stream learning, espera-se que haja alguma latência de verificação na obtenção dos rótulos das instâncias, um cenário conhecido como rótulos atrasados. Nesses casos, o rótulo pode ser adquirido após um atraso fixo (onde o rótulo de uma instância pode ser obtido após um número fixo de timestamps) ou um atraso variável (onde cada instância tem um atraso diferente e desconhecido). Em alguns cenários, os rótulos podem nunca se tornar disponíveis, levando ao que é conhecido como cenário de atraso infinito. Além disso, há cenários de aprendizado (com fluxos de dados parcialmente rotulados atrasados) onde coexistem instâncias rotuladas, não rotuladas e atrasadas. Assim, há vários desafios relevantes em relação à disponibilidade de instâncias rotuladas e o atraso na obtenção dos rótulos correspondentes.

Embora trabalhos recentes tenham explorado atualizações de modelos usando rótulos atrasados, a maioria deles examinou apenas cenários com atrasos fixos. Além disso, alguns se concentraram em situações em que apenas uma parte das instâncias seria rotulada. Neste projeto, investigaremos um cenário diferente envolvendo rótulos atrasados, em que todas as instâncias no fluxo são eventualmente rotuladas, mas o atraso na obtenção desses rótulos varia. Problemas do mundo real que consistem desse cenário incluem detecção de fraudes em cartões de crédito, detecção de intrusão em redes de computadores e previsão de defeitos de software. Nesses exemplos, o atraso na obtenção de rótulos para certas classes de instâncias pode ser significativamente maior do que para outras. Por exemplo, transações fraudulentas podem ser mais difíceis de rotular em comparação com transações não fraudulentas, e detectar um ataque pode exigir mais recursos do que reconhecer o acesso normal. Além disso, mesmo dentro da mesma classe, o atraso na obtenção de rótulos pode diferir.

A pesquisa realizada pelo candidato contribuirá para responder questões de pesquisa relevantes como:

1) Instâncias recentes não rotuladas podem melhorar o desempenho preditivo de modelos de classificação juntamente com instâncias rotuladas com atrasos variados? Em que medida? A motivação para esta questão é verificar se o aprendizado semissupervisionado pode melhorar o desempenho do classificador em vez de depender apenas de abordagens supervisionadas que exigem instâncias rotuladas para atualizar o modelo.

2) Como a severidade de desvios de conceito (desafio frequentemente presente em ambientes não estacionários) impacta o uso de rótulos com atraso para atualizar modelos de classificação? A motivação para esta questão é analisar se, quando ocorre um desvio de conceito entre a chegada de uma instância e seu rótulo correspondente, esta instância deve ser menos importante na atualização do modelo e se a severidade do desvio ou o tipo de desvio (gradual ou abrupto) também podem ser considerados.

3) Em quais situações instâncias de dados rotulados ponderados, com base em seu atraso, podem melhorar o desempenho preditivo dos modelos de classificação? A motivação é verificar se adicionar um peso a cada instância rotulada pode ser eficaz e quais os principais problemas a serem abordados nesse tipo de estratégia.

**Universidade Federal de Pernambuco
Centro de Informática (CIn)
Programa de Pós-Graduação em Ciência da Computação**

Gregory Ditzler, Manuel Roveri, Cesare Alippi, and Robi Polikar. Learning in nonstationary environments: A survey. *IEEE Computational Intelligence Magazine*, 10(4):12–25, 2015.

Bruno Veloso, João Gama, Benedita Malheiro, e João Vinagre. Hyperparameter self-tuning for data streams. *Information Fusion*, 76:75–86, dec 2021.

R. G. F. Soares and L. L. Minku, "OSNN: An Online Semisupervised Neural Network for Nonstationary Data Streams," in *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 9, pp. 6029-6041, Sept. 2023, doi: 10.1109/TNNLS.2021.3132584.

C.M. Bishop: *Pattern Recognition and Machine Learning*. Springer (2006)

Chapelle, O., Schölkopf, B., Zien, A. (eds.): *Semi-Supervised Learning*. MIT Press (2006)
