

TEMA PARA PRÉ-PROJETO DE MESTRADO E DOUTORADO

1 - Identificação

Título do Projeto:	Algoritmos de data stream learning para a melhoria da qualidade do desenvolvimento de software
Orientador:	Rodrigo Gabriel Ferreira Soares
Grande Área:	Ciência da Computação
Área do Conhecimento:	Aprendizagem de Máquina e Mineração
Instituição de Execução:	Universidade Federal de Pernambuco - Centro de Informática (CIn-UFPE)

2 - Introdução

Produzir sistemas de software cada vez maiores e mais complexos em maior velocidade é um grande desafio para a indústria. Esta demanda ocasiona defeitos de software que têm um impacto significativo na aceitação do produto. Estima-se que correções em softwares custam mundialmente 381 bilhões de dólares anualmente. Reduzir e corrigir defeitos de software são problemas importantes, ainda mais com a forte pressão para produção de soluções rápidas. Essa velocidade das entregas faz com que desenvolvedores priorizem determinadas partes do código-fonte para inspeção e teste. A qualidade dessa priorização pode levar ao sucesso ou à falha no desenvolvimento de um sistema de software. Este projeto irá estudar novos algoritmos de aprendizado online para acelerar a adaptação a desvios de conceito inerentes à predição de mudanças críticas em softwares. As soluções encontradas por este projeto, quando integradas a sistemas de controle de versão de software, fornecerão alertas precoces, confiáveis e automatizados de alterações indutoras de defeitos ao longo da vida útil dos projetos de software.

3 - Objetivos

O objetivo geral deste projeto é o desenvolvimento de técnicas de Aprendizado de Máquina para predição de erros no desenvolvimento de software.

Os objetivos específicos são:

- Construir base de dados com informações relevantes do desenvolvimento de software.
-

Universidade Federal de Pernambuco
Centro de Informática (CIn)
Programa de Pós-Graduação em Ciência da Computação

- Extrair características relevantes para predição de erros em desenvolvimento de software.
 - Estudar o problema de predição de erros em software sob a perspectiva de data stream learning.
 - Propor algoritmos inteligentes eficientes para data stream learning capazes de lidar com os desafios impostos pela predição automática de erros em software.
 - Integração dos algoritmos propostos ao fluxo de desenvolvimento de software praticado na indústria.
 - Avaliação da ferramenta proposta em ambiente de mundo real.
-

4 - Metodologia

Este projeto consiste de quatro fases, cada uma delas com atividades a serem realizadas pelo candidato como segue.

1. Fase 1: Estudo bibliográfico e capacitação em desenvolvimento.

- a. Estudo e revisão bibliográfica de técnicas atuais de predição de defeitos de software.
- b. Estudo sobre arquiteturas em nuvem. O candidato irá compreender os conceitos e técnicas de sistemas baseados em nuvem em Python para futura implementação da ferramenta, potencialmente o candidato irá estudar arquiteturas de Application Programming Interface (API).
- c. O estudo das técnicas de Aprendizado de Máquina. O candidato irá estudar implementação disponíveis publicamente para aplicações. Ele irá integrar estes frameworks à ferramenta proposta.

2. Fase 2: Testes dos algoritmos propostos

- a. Realizar testes com os modelos propostos e comparar seu desempenho. Devido à complexidade inerente, esta é a atividade onde a maior parte dos esforços deste projeto serão concentrados.

3. Fase 3: Implementação de modelos e da ferramenta.

- a. Implementação. O candidato irá implementar um protótipo do sistema em linguagem de programação apropriada com todos os componentes da ferramenta proposta.
- b. Criação e implementação de bancos de dados. O candidato irá criar as conexões necessárias com componentes externos ao sistema, bem como criar a sua base de dados.
- c. Avaliação da ferramenta. O candidato irá avaliar a eficácia da ferramenta com dados sintéticos e dados reais oriundos de empresas de desenvolvimento de software.

4. Fase 4: Avaliação com ambiente real de desenvolvimento de software.

- a. Coleta e adequação de dados. O candidato irá coletar dados de mundo real de desenvolvimento de software para validação da ferramenta
- b. Implementação da integração do protótipo da ferramenta com ambiente de empresa de desenvolvimento de software.
- c. Avaliação da ferramenta. O candidato irá coletar dados de satisfação dos desenvolvedores de software após testes do protótipo.

5. Fase 5: Publicações

- a. Escrita de relatórios e artigos científicos com os resultados deste projeto.

5 - Resultados esperados

O principal resultado deste projeto é a proposição de modelos preditivos para alertar desenvolvedores sobre potenciais erros nos commits diários em um projeto de software. O candidato irá também avaliar estas soluções no fluxo de trabalho de desenvolvedores de software em projetos publicamente disponíveis. Tal integração é mais um resultado de impacto deste plano. A formação do candidato será realizada através da experiência do candidato junto ao desenvolvimento de uma solução que requer alto grau de especialização e sofisticação que compreende áreas muito importantes atualmente: Engenharia de Software e Aprendizado de Máquina.

6 - Referências

R G F Soares, L L Minku, "Online ensemble model compression for nonstationary data stream learning" Neural Networks, vol. 185, 2025.

R G F Soares, L L Minku, "OSNN: An online semisupervised neural network for nonstationary data streams" IEEE Trans. Neu. Net. Learn. Sys., vol. 34, no. 9, 2023

R. G. F. Soares, H. Chen, and X. Yao. Semisupervised classification with cluster regularization. IEEE Transactions on Neural Networks and Learning Systems, 23(11):1779–1792, November 2012.

SOARES, R. G. F.; FEITOSA, A. P. S. C.; GONCALVES, G.; VIDAL, D. A.. Self-evolving optimization for data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2024, Auckland. Neural Information Processing - Communications in Computer and Information Science. Springer Nature, 2025, v.2283.

VIDAL, D. A.; SOARES, R. G. F.; GONCALVES, G.; FEITOSA, A. P. S. C.; TAVARES, K. M.; SERUFFO, M. C. R.. A weight averaging neural network for semi-supervised data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2025, Auckland. Neural Information Processing - LNCS. Springer Nature, 2025, v.15287.

M. Belkin, P. Niyogi, e V. Sindhwani. Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. The Journal of Machine Learning Research, 7:2399–2434, 2006.

C. M. Bishop. Pattern Recognition and Machine Learning. Springer, 2006.

K. P. Murphy. The Machine Learning: A Probabilistic Perspective. Mit Press, 2012. ISBN 978-0262018029.
