

TEMA PARA PRÉ-PROJETO DE MESTRADO E DOUTORADO

1 - Identificação

Título do Projeto:	Algoritmos eficientes para aprendizagem de máquina semissupervisionada
Orientador:	Rodrigo Gabriel Ferreira Soares
Grande Área:	Ciência da Computação
Área do Conhecimento:	Aprendizagem de Máquina e Mineração
Instituição de Execução:	Universidade Federal de Pernambuco - Centro de Informática (CIn-UFPE)

2 - Introdução

Classificação semissupervisionada consiste em adquirir conhecimento a partir de dados rotulados e não rotulados para classificar instâncias ainda não conhecidas. Este projeto contribuirá no desenvolvimento de algoritmos eficientes para conjuntos de dados semissupervisionados de larga escala. Tal eficiência não é encontrada nos métodos atuais. Dados não rotulados são geralmente abundantes neste tipo de classificação, assim faz-se necessário métodos que possam lidar de forma eficaz e eficiente com classificação multi-classe.

Devido ao grande número de dados não rotulados disponíveis, conjuntos de treinamento semissupervisionados muitas vezes têm milhões de instâncias. Portanto, os algoritmos de Aprendizagem de Máquina (AM) devem ser capazes de lidar com esses conjuntos de dados em larga escala. Recentemente, vários métodos baseados em ensemble têm sido introduzidos com melhor desempenho quando comparados com a generalização gerada por modelos individuais. No entanto, os algoritmos de ensemble existentes não são capazes de lidar com conjuntos de dados semissupervisionados de larga escala.

Algoritmos de ensemble têm sido empregados com sucesso em ambos os treinamentos supervisionado e semissupervisionado para melhorar a generalização quando comparado com classificadores individuais. No entanto, a utilização das técnicas de comitês existentes está limitada a pequenas bases de dados devido aos requisitos de tempo e memória. Algumas abordagens de ensembles multi-classe têm sido propostas, no entanto, esses algoritmos não exploraram as estruturas

Universidade Federal de Pernambuco
Centro de Informática (CIn)
Programa de Pós-Graduação em Ciência da Computação

dos dados como partições fuzzy, considerando os clusters como conjuntos disjuntos. Tipicamente, os classificadores propostos requerem grandes quantidades de memória, o que pode degradar tanto o tempo quanto a eficiência de memória e, assim, pode limitar seu uso em grandes conjuntos de dados.

Há um relacionamento entre aprendizagem online e aprendizagem de larga escala. Algoritmos de aprendizagem online processam cada instância no máximo uma só vez em vez de processarem cada dado várias vezes, o que torna esse tipo de abordagem mais adequada para conjunto de dados de larga escala. Podemos nos inspirar em técnicas de ensemble para aprendizagem online, para conseguir eficiência quando lidando com conjuntos de larga escala.

O candidato irá participar do estudo e desenvolvimento de técnicas para que os algoritmos desenvolvidos no projeto de pesquisa possam ser usados para problemas de larga escala, ou seja, ele auxiliará na confecção desses algoritmos a fim de reduzir tanto suas complexidades de tempo computacional quanto as complexidades de memória requerida.

3 - Objetivos

O candidato deverá investigar e propor modelos eficientes para problemas semissupervisionados. Tais métodos deverão ter menor complexidades de tempo e de memória do que métodos do estado da arte, de modo que predições possam ser realizadas em bases de dados de larga escala. Consideramos os conjuntos de dados em larga escala como conjuntos de dados com milhões de pontos. Assim, a realização deste projeto ajudará na superação das limitações de algoritmos existentes na literatura através da investigação de técnicas para reduzir os requerimentos de tempo e memória dos algoritmos propostos. Os objetivos específicos do candidato são:

- Estudo e compreensão de conceitos e métodos de AM, estatística e cálculo. Além de estudar complexidade algorítmica e crescimento de funções. Estudar e compreender modelos estatísticos e computacionais eficientes para AM.
- Compreensão e participação no processo científico em computação. Contribuir para que os métodos propostos possam ser aplicados a problemas de larga escala.
- Construção de conhecimento multidisciplinar nos domínios onde os algoritmos serão aplicados, usando referenciais matemáticos, estatísticos e computacionais.
- Construção de bases de dados de mundo real e artificiais.
- Estudo de métodos de amostragem, agrupamento e de busca apropriados para grandes volumes de dados. Estudo de linguagens de programação apropriadas para implementação dos algoritmos propostos.
- Auxílio na implementação dos algoritmos propostos na linguagem de programação escolhida
- Avaliação dos requerimentos de tempo e memória dos métodos propostos.
- Realizar testes com os modelos propostos e avaliar seu desempenho preditivo.

4 - Metodologia

Revisão da literatura. A avaliação da literatura usará livros de bibliotecas públicas e artigos de periódicos e de anais de congressos em AM publicamente disponíveis.

Geração e coleta de bases de dados de larga escala. Usaremos bases de dados artificiais de larga escala geradas para avaliar a capacidade de generalização dos algoritmos propostos em um ambiente controlado. Coletaremos diversas bases de dados reais de problemas de larga escala disponíveis publicamente de diferentes domínios do conhecimento.

Análise de complexidade algorítmica. Análise dos requerimentos de tempo e memória dos algoritmos propostos.

Estudo de métodos de amostragem e computação paralela. Estudaremos técnicas de amostragem e computação paralela para lidar com grandes volumes de dados. Além de técnicas de agrupamento eficientes da literatura.

Estudo e proposição de métodos de AM. Estudaremos redes neurais artificiais, árvores de decisão, ensembles, métodos de agrupamento, algoritmos de otimização, entre outros, para concepção de novos algoritmos de AM.

Ambientes de desenvolvimento. O candidato realizará as implementações da pesquisa usando ambientes, linguagens de programação e bibliotecas publicamente disponíveis.

Avaliação dos métodos propostos. O candidato deverá avaliar o desempenho preditivo dos modelos propostos e suas aplicabilidades a bases de dados de diferentes complexidades, de forma a mostrar sua relevância e benefícios. Além disso, ele avaliará os requisitos de tempo computacional e de memória destes algoritmos.

Escrita de artigos científicos. O candidato deverá publicar os resultados deste projeto em periódicos relevantes internacionalmente.

5 - Resultados esperados

Espera-se que o candidato obtenha experiência e conhecimentos sobre os fundamentos da área de AM, especialmente em data stream learning. É esperado que o candidato proponha novos algoritmos inteligentes que possam realizar predição de forma eficaz e eficiente em problemas de diversos domínios. Os algoritmos propostos deverão lidar com grandes conjuntos de dados, empregando um algoritmo de agrupamento eficiente, uma técnica de aproximação para os vizinhos mais próximos para evitar o cálculo da matriz de distâncias e um procedimento de amostragem para reduzir o conjunto de treinamento de classificadores base. Espera-se também a publicação dos resultados do projeto em periódicos de relevância internacional.

6 - Referências

R. G. F. Soares, H. Chen, and X. Yao. Semisupervised classification with cluster regularization. *IEEE Transactions on Neural Networks and Learning Systems*, 23(11):1779–1792, November 2012.

R. G. Soares and L. L. Minku, “Online ensemble model compression for nonstationary data stream learning,” *Neural Networks*, vol. 185, p. 107151, 2025.

R. G. F. Soares and L. L. Minku, “OSNN: An online semisupervised neural network for nonstationary data streams,” *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 9, pp. 6029–6041, 2023.

SOARES, R. G. F.; FEITOSA, A. P. S. C.; GONCALVES, G.; VIDAL, D. A.. Self-evolving optimization for data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2024, Auckland. *Neural Information Processing - Communications in Computer and Information Science*. Springer Nature, 2025, v.2283.

VIDAL, D. A.; SOARES, R. G. F.; GONCALVES, G.; FEITOSA, A. P. S. C.; TAVARES, K. M.; SERUFFO, M. C. R.. A weight averaging neural network for semi-supervised data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2025, Auckland. *Neural Information Processing - LNCS*. Springer Nature, 2025, v.15287.

Thorsten Joachims. Transductive learning via spectral graph partitioning. In *Proceedings of the International Conference on Machine Learning (ICML)*, pages 290–297, 2003.

Martin Szummer and Tommi Jaakkola. Partially labeled classification with markov random walks. In *Advances in Neural Information Processing Systems (NIPS)*, pages 945–952. MIT Press, 2002.

Xiaojin Zhu and Zoubin Ghahramani. Learning from labeled and unlabeled data with label propagation. Technical report, Carnegie Mellon University (CMU), 2002.

Hamed Valizadegan, Rong Jin, and Anil K. Jain. Semi-supervised boosting for multi-class classification. In *Proceedings of the European Conference on Machine Learning and Knowledge Discovery in Databases - Part II (ECML/PKDD)*, pages 522–537, Berlin, Heidelberg, 2008. Springer-Verlag.

Ke Chen and Shihai Wang. Semi-supervised learning via regularized boosting working on multiple semisupervised assumptions. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(1):129–143, January 2011.

Xinlei Chen and Deng Cai. Large scale spectral clustering with landmark-based representation. In *Proceedings of the Twenty-Fifth AAAI Conference on Artificial Intelligence*, pages 313–318, 2011.

O. Delalleau, Y. Bengio, and N. Le Roux. Large-scale algorithms. In O. Chapelle, B. Schölkopf, and A. Zien, editors, *Semi-supervised learning*, chapter 18. MIT Press, 2006
