

TEMA PARA PRÉ-PROJETO DE MESTRADO E DOUTORADO

1 - Identificação

Título do Projeto:	Modelos Autoajustáveis para Aprendizagem de Máquina Semissupervisionada
Orientador:	Rodrigo Gabriel Ferreira Soares
Grande Área:	Ciência da Computação
Área do Conhecimento:	Aprendizagem de Máquina e Mineração
Instituição de Execução:	Universidade Federal de Pernambuco - Centro de Informática (CIn-UFPE)

2 - Introdução

Técnicas tradicionais de Aprendizado de Máquina (AM) usam apenas instâncias rotuladas (ou seja, os pares de características e rótulos) para realizar o treinamento. No entanto, os dados rotulados são normalmente caros e de difícil obtenção. Por exemplo, uma tarefa de aprendizado pode exigir sensores caros e especialistas humanos para reunir e rotular todos os dados. Em contraste, instâncias não rotuladas podem ser abundantes e facilmente obtidas. Daí, é natural que se estude o emprego de tais dados não rotulados para melhorar o desempenho preditivo de um classificador. O aprendizado semissupervisionado usa grandes quantidades de instâncias sem rótulo, juntamente com dados rotulados para construir máquinas de aprendizado mais efetivas. Como o aprendizado semissupervisionado requer menos custos e proporciona potencialmente maior precisão, ele se tornou popular na comunidade de aprendizado de máquina na teoria e na prática.

A Classificação Semissupervisionada (CSS) é um desafio devido à relação desconhecida entre a verdadeira fronteira de decisão e a distribuição de dados. Na AM supervisionada, essa relação pode ser irrelevante, como uma fronteira de decisão que é independente da distribuição dos dados. Por outro lado, mesmo que não haja essa relação em um determinado conjunto de dados, podemos não saber qual hipótese deve ser levantada por um classificador sobre os dados. Quando a hipótese levantada é correta, o desempenho de generalização de um algoritmo de CSS é geralmente superior ao desempenho de métodos supervisionados.

Para conjuntos de dados do mundo real, podemos não ter conhecimento prévio da estrutura de classe verdadeira e sua suposição CSS correspondente. Intuitivamente, se o conjunto de dados tem uma estrutura de manifold, espera-se que os algoritmos que usam a suposição de manifold para entregar um desempenho melhor quando comparado a outros métodos do CSS. Este é também o caso de conjuntos de dados em que a suposição de agrupamento é verdadeira.

Vários classificadores existentes implementam todas as três hipóteses: smoothness, manifold e agrupamento. Esses algoritmos podem produzir um melhor desempenho do que métodos especializados (por exemplo, os classificadores que implementam apenas a hipótese de agrupamento), com a hipótese incorreta implementada. No entanto, em casos em que há uma estrutura de grupos (clusters) clara para as classes, a qualidade da fronteira de decisão gerada por estes algoritmos pode ser limitada pela busca equivocada por um manifold. Além disso, esses métodos também dependem do compromisso entre as hipóteses, que pode ser uma tarefa desafiadora. Por isso, em tais situações, classificadores especializados em encontrar clusters (grupos), ou seja classificação baseada em clusters, podem produzir desempenho de generalização significativamente superior.

O candidato deverá desenvolver e validar novos algoritmos inteligentes que selecionem sistematicamente hipóteses de CSS a partir dos dados de entrada. Ou seja, ele investigará mecanismos que permitam a identificação automática do melhor compromisso entre as diversas hipóteses de CSS para dados de diversos domínios.

3 - Objetivos

Este projeto tem como objetivo auxiliar na superação das limitações de algoritmos existentes na literatura através da investigação de métodos automáticos para balancear as diversas hipóteses presentes em conjuntos de dados semissupervisionados. Os objetivos específicos do candidato são:

- Estudo e compreensão de conceitos e métodos de aprendizado de máquina, estatística e cálculo.
 - Compreensão e participação no processo científico em computação. Contribuir para a concepção dos métodos propostos.
 - Construção de conhecimento multidisciplinar nos domínios onde os algoritmos serão aplicados, usando referenciais matemáticos, estatísticos e computacionais.
 - Criação de bases de dados artificiais e coletar bases de dados do mundo real que possam ser usadas para validar os algoritmos propostos.
 - Compreensão dos algoritmos propostos e implementá-los na linguagem de programação escolhida.
 - Estudo e compreensão de modelos estatísticos e computacionais para seleção automática de parâmetros de hipóteses de CSS.
 - Avaliação dos métodos propostos. O candidato deverá avaliar o desempenho preditivo dos modelos propostos e suas aplicabilidades a bases de dados de diferentes complexidades, de forma a mostrar sua relevância e benefícios. Além disso, ele avaliará os requisitos de tempo computacional e de memória destes algoritmos.
 - Escrita de artigos científicos. O candidato deverá publicar os resultados deste projeto em periódicos relevantes internacionalmente.
-

4 - Metodologia

Revisão da literatura. A avaliação da literatura usará livros de bibliotecas públicas e artigos de periódicos e de anais de congressos em AM publicamente disponíveis.

Geração e coleta de bases de dados. Usaremos bases de dados artificiais geradas para avaliar a capacidade de generalização dos algoritmos propostos em um ambiente controlado. Coletaremos diversas bases de dados reais de problemas disponíveis publicamente de diferentes domínios do conhecimento.

Análise de complexidade algorítmica. Análise dos requerimentos de tempo e memória dos algoritmos propostos.

Estudo de métodos de amostragem e computação paralela. Estudaremos técnicas de amostragem e computação paralela para lidar com grandes volumes de dados. Além de técnicas de agrupamento eficientes da literatura.

Estudo e proposição de métodos de AM. Estudaremos redes neurais artificiais, árvores de decisão, ensembles, métodos de agrupamento, algoritmos de otimização, entre outros, para concepção de novos algoritmos de AM.

Ambientes de desenvolvimento. O candidato realizará as implementações da pesquisa usando ambientes, linguagens de programação e bibliotecas publicamente disponíveis.

Avaliação dos métodos propostos. O candidato deverá avaliar o desempenho preditivo dos modelos propostos e suas aplicabilidades a bases de dados de diferentes complexidades, de forma a mostrar sua relevância e benefícios. Além disso, ele avaliará os requisitos de tempo computacional e de memória destes algoritmos.

Escrita de artigos científicos. O candidato deverá publicar os resultados deste projeto em periódicos relevantes internacionalmente.

5 - Resultados esperados para o período da bolsa

Espera-se que o candidato obtenha experiência e conhecimentos sobre os fundamentos da área de AM, especialmente em Aprendizagem Semissupervisionada. É esperado que o candidato proponha novos algoritmos inteligentes que possam realizar predição de forma eficaz e eficiente em problemas de diversos domínios com dados rotulados e não rotulados. Os algoritmos propostos deverão lidar de forma automática e eficiente com as várias possíveis hipóteses de CSS a partir dos dados de entrada destes modelos. Espera-se também a publicação dos resultados do projeto em periódicos de relevância internacional.

6 - Referências

R G F Soares, L L Minku, "Online ensemble model compression for nonstationary data stream learning" Neural Networks, vol. 185, 2025.

R G F Soares, L L Minku, "OSNN: An online semisupervised neural network for nonstationary data streams" IEEE Trans. Neu. Net. Learn. Sys., vol. 34, no. 9, 2023

R. G. F. Soares, H. Chen, and X. Yao. Semisupervised classification with cluster regularization. IEEE Transactions on Neural Networks and Learning Systems, 23(11):1779–1792, November 2012.

SOARES, R. G. F.; FEITOSA, A. P. S. C.; GONCALVES, G.; VIDAL, D. A.. Self-evolving optimization for data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2024, Auckland. Neural Information Processing - Communications in Computer and Information Science. Springer Nature, 2025, v.2283.

VIDAL, D. A.; SOARES, R. G. F.; GONCALVES, G.; FEITOSA, A. P. S. C.; TAVARES, K. M.; SERUFFO, M. C. R.. A weight averaging neural network for semi-supervised data stream learning In: 31st International Conference on Neural Information Processing (ICONIP), 2025, Auckland. Neural Information Processing - LNCS. Springer Nature, 2025, v.15287.

M. Belkin, P. Niyogi, e V. Sindhwani. Manifold regularization: A geometric framework for learning from labeled and unlabeled examples. The Journal of Machine Learning Research, 7:2399–2434, 2006.

C. M. Bishop. Pattern Recognition and Machine Learning. Springer, 2006.

K. P. Murphy. The Machine Learning: A Probabilistic Perspective. Mit Press, 2012. ISBN 978-0262018029.
